

گزارش نهایی پروژه داده‌کاوی

طبقه‌بندی چندکلاسه با استفاده از روش‌های یادگیری ماشین

درس: داده‌کاوی

دانشکده علوم کامپیوتر، دانشگاه تهران

نیم‌سال بهار ۱۴۰۵

نام و نام خانوادگی	شماره دانشجویی	گروه
رادمهر میرادی	۶۱۰۳۰۲۲۰۱	۲۸
مریم تقی‌نسب	۶۱۰۳۰۲۱۳۲	۲۸

تاریخ تهیه گزارش: مرداد ۱۴۰۵

۱. چکیده

هدف پروژه، ساخت یک مسیر کامل و قابل اجرا برای طبقه‌بندی چندکلاسه روی داده اختصاصی گروه ۲۸ بود. فایل آموزشی ۱۰۰,۰۰۰ نمونه و ویژگی دارد و ستون y چهار کلاس هدف را نشان می‌دهد. توزیع کلاس‌ها نامتوازن است؛ به همین دلیل در کنار Accuracy از Precision, Recall, Macro F1-score, Weighted F1-score و ماتریس درهم‌ریختگی استفاده شد.

در پیش‌پردازش، ۱۳۸ ردیف تکراری و ستون ثابت f11 حذف شد، ویژگی زمانی f14 به سال، ماه، روز، ساعت و روز هفته تبدیل شد و مقادیر گم‌شده داخل Pipeline مدیریت شدند. سه مدل Logistic Regression, Decision Tree و Random Forest پیش و پس از انتخاب ویژگی مقایسه شدند. مدل Random Forest با ۲۵ ویژگی منتخب، Accuracy برابر 0.6794، Macro F1-score برابر 0.4923 و Weighted F1-score برابر 0.7221 به دست آورد و به‌عنوان مدل نهایی انتخاب شد.

۲. مقدمه

هدف اصلی این پروژه صرفاً رسیدن به یک عدد دقت بالا نبود. تلاش کردیم مسئله را از شناخت داده تا ارزیابی مدل به‌صورت منظم پیش ببریم و برای هر تصمیم، از حذف ستون ثابت تا انتخاب معیار ارزیابی، دلیل مشخصی داشته باشیم. داده شامل ویژگی‌های عددی، دسته‌ای، بولی و زمانی است و همین تنوع، پیش‌پردازش یکسان برای همه ستون‌ها را نامناسب می‌کند.

چالش مهم‌تر، نامتوازن بودن کلاس‌هاست. حدود چهار پنجم نمونه‌ها به کلاس ۲ تعلق دارند و کلاس ۱ کمتر از یک درصد داده را تشکیل می‌دهد. در چنین وضعیتی Accuracy می‌تواند تصویر خوش‌بینانه‌ای از مدل نشان دهد. بنابراین Macro F1-score معیار اصلی انتخاب مدل قرار گرفت، چون به هر کلاس وزن یکسان می‌دهد. در ادامه، روش انجام کار و نتایج مدل‌ها با همین نگاه گزارش می‌شود.

۳. روش‌شناسی


۳.۱. شناخت داده و تعریف مسئله

هر ردیف یک نمونه برای پیش‌بینی کلاس هدف است. داده خارجی استفاده نشده و همه تحلیل‌ها بر همان فایل اختصاصی گروه ۲۸ انجام شده است. مشخصات اصلی داده در جدول ۱ آمده است.

جدول ۱ - مشخصات اصلی مجموعه داده

مشخصه	مقدار
تعداد نمونه	۱۰۰,۰۰۰
تعداد ویژگی	۳۴
ویژگی‌های عددی / دسته‌ای / بولی	۸ / ۱۵ / ۱۱
ستون هدف	y
تعداد کلاس	۴
نوع مسئله	Multi-class Classification

شکل ۱ - توزیع کلاس‌های متغیر هدف




کلاس ۲ با ۷۹۷۲۵ نمونه، کلاس غالب است. در مقابل، کلاس ۱ فقط ۷۷۹ نمونه دارد. این اختلاف زیاد دلیل استفاده از `class_weight=balanced` و معیارهای macro در آموزش و ارزیابی است.

۳.۲. تحلیل اکتشافی داده

در بررسی اولیه، تعداد مقادیر گمشده، ردیف‌های تکراری، تعداد مقادیر یکتا، ستون‌های ثابت، توزیع ویژگی‌های عددی و ارتباط آن‌ها با هدف بررسی شد. در مجموع ۱۳۸ ردیف کاملاً تکراری وجود داشت. ستون f11 فقط مقدار US را نگه می‌داشت و هیچ قدرت تفکیکی نداشت.

شکل ۲ - بیشترین درصد مقادیر گمشده



بیشترین مقدار گمشده مربوط به f4 با 44.23 درصد است. پس از آن f21 و f16 به ترتیب 28.50 و 26.08 درصد مقدار گمشده دارند. حذف همه ردیف‌های دارای مقدار خالی بخش بزرگی از داده را از بین می‌برد؛ بنابراین برای ویژگی‌های عددی جایگزینی با میانه و برای ویژگی‌های دسته‌ای مقدار Unknown استفاده شد.

۳.۳. پاک‌سازی و پیش‌پردازش

پس از حذف ردیف‌های تکراری، ۹۹۰۸۶۲ نمونه باقی ماند. ستون f14 بدون خطای تبدیل به تاریخ و زمان خوانده شد و پنج ویژگی f14_year, f14_month, f14_day, f14_hour و f14_dayofweek از آن استخراج شد. ویژگی‌های بولی به صفر و یک تبدیل شدند.


ویژگی‌های دسته‌ای با حداکثر ۲۰ مقدار یکتا One-Hot شدند. ستون‌های f13, f10, f9, f8, f7, f6 و f22 به دلیل کاردینالیتی بالا در مدل پایه کنار گذاشته شدند تا ابعاد داده کنترل شود. جایگزینی مقدار گمشده، استانداردسازی و کدگذاری داخل ColumnTransformer و Pipeline انجام شد. به این ترتیب، پارامترهای پیش‌پردازش فقط از بخش آموزش یاد گرفته شدند و روی آزمون اعمال شدند.

داده با نسبت ۸۰ به ۲۰ و با روش stratified تقسیم شد. random_state برابر 42 در تمام مراحل ثابت نگه داشته شد تا نتایج قابل بازتولید باشند.

۳.۴. انتخاب ویژگی

برای رعایت سقف ۲۵ ویژگی، Random Forest ابتدا فقط روی بخش آموزش برازش شد. اهمیت ستون‌های تولیدشده پس از One-Hot Encoding به نام ویژگی اصلی برگردانده و با هم جمع شد. سپس ۲۵ ویژگی با بیشترین اهمیت انتخاب شدند. در این مرحله از داده آزمون استفاده نشد.

شکل ۳ - پانزده ویژگی با بیشترین اهمیت تجمیع‌شده



جدول ۲ - مجموعه ۲۵ ویژگی منتخب

۱	۲	۳	۴	۵
f14_year	f5	f1	f4	f16
f3	f14_month	f2	f30	f18
f15	f14_hour	f12	f17	f14_day
f20	f25	f14_dayofweek	f34	f33
f19	f31	f32	f28	f21

۳.۵. مدل‌ها و معیارهای ارزیابی

Logistic Regression به‌عنوان خط پایه ساده، Decision Tree برای مدل‌سازی روابط غیرخطی با ساختار قابل‌تفسیر، و Random Forest برای ترکیب چند درخت بررسی شدند. برای دو مدل درختی، عمق و حداقل تعداد نمونه در گره‌ها محدود شد تا پیچیدگی کنترل شود. در هر سه مدل از وزن متوازن کلاس‌ها استفاده شد.

معیارهای ارزیابی شامل Accuracy, Precision, Recall, Macro F1-score, Weighted F1-score و Confusion Matrix بود. با توجه به عدم توازن کلاس‌ها، انتخاب نهایی بر Macro F1-score استوار شد؛ اما اختلاف آن با Accuracy و معیارهای کلاسی نیز در تحلیل لحاظ شد.

۴. نتایج و تحلیل


۴.۱. مقایسه مدل‌ها

جدول ۳ نتایج هر سه مدل را پیش و پس از انتخاب ویژگی نشان می‌دهد. اعداد از اجرای کامل نوت‌بوک روی همان تقسیم آموزش و آزمون استخراج شده‌اند.

جدول ۳ - مقایسه نهایی عملکرد مدل‌ها

مدل	Accuracy	Macro F1	Weighted F1
Random Forest Selected	0.6794	0.4923	0.7221
Random Forest	0.6753	0.4872	0.7187
Decision Tree	0.6031	0.4466	0.6603
Decision Tree Selected	0.6060	0.4452	0.6637
Logistic Regression	0.4141	0.3029	0.4811
Logistic Regression Selected	0.4116	0.3017	0.4782

شکل ۴ - مقایسه Macro F1-score مدل‌ها



Random Forest با ۲۵ ویژگی منتخب بهترین نتیجه را دارد. انتخاب ویژگی، Accuracy را از 0.6753 به 0.6794 و Macro F1-score را از 0.4872 به 0.4923 رساند. تغییر کوچک اما هم‌زمان با کاهش تعداد ویژگی‌ها رخ داده است. در Decision Tree و Logistic Regression انتخاب ویژگی بهبود مشابهی ایجاد نکرد.


۴.۲. تحلیل مدل نهایی

عملکرد کلاس به کلاس نشان می‌دهد مدل برای کلاس‌های کم‌تعداد Recall بالایی دارد، اما Precision آن‌ها پایین‌تر است. این رفتار با وزن‌دهی متوازن کلاس‌ها سازگار است: مدل نمونه‌های بیشتری را به کلاس‌های اقلیت نسبت می‌دهد تا از دست رفتن آن‌ها کمتر شود، اما بخشی از این پیش‌بینی‌ها مثبت کاذب هستند.

جدول ۴ - گزارش کلاسی Random Forest با ویژگی‌های منتخب

کلاس	Precision	Recall	F1-score	Support
۱	0.24	0.94	0.38	155
۲	0.96	0.65	0.78	15,921
۳	0.42	0.82	0.56	3,366
۴	0.16	0.63	0.25	531

شکل ۵ - ماتریس درهم‌ریختگی مدل نهایی



مدل ۱۴۶ نمونه از ۱۵۵ نمونه کلاس ۱ را درست تشخیص داده است. برای کلاس ۲، تعداد ۱۰۳۴۱ پیش‌بینی درست ثبت شد، اما بخشی از نمونه‌های این کلاس به کلاس‌های ۳ و ۴ نسبت داده شدند. کلاس ۴ کمترین F1-score را دارد و تشخیص دقیق آن دشوارتر است. در نتیجه، مدل برای شناسایی اقلیت‌ها حساس است، ولی در کاربردی که هزینه مثبت کاذب بالا باشد باید آستانه تصمیم یا راهبرد متوازن‌سازی با دقت بیشتری تنظیم شود.

پارامترهای مدل نهایی عبارت‌اند از ۱۰۰ درخت، عمق حداکثر ۱۵، `min_samples_split` برابر ۵۰، `min_samples_leaf` برابر ۲۰، `class_weight=balanced` و `random_state=42`. این تنظیمات همان رویکرد نسخه اولیه را حفظ می‌کنند و جست‌وجوی گسترده ابرپارامترها انجام نشده است.

۵. نتیجه‌گیری

پروژه یک مسیر کامل داده‌کاوی را روی داده اختصاصی گروه ۲۸ اجرا کرد: شناخت داده، تحلیل اکتشافی، پاک‌سازی، ساخت ویژگی زمانی، پیش‌پردازش بدون نشت داده، مقایسه سه مدل، انتخاب ۲۵ ویژگی و ارزیابی نهایی. Random Forest با ویژگی‌های منتخب بهترین نتیجه را به دست آورد و در عین رعایت محدودیت پروژه، اندکی از نسخه پایه بهتر بود.

Macro F1-score برابر 0.4923 نشان می‌دهد مسئله با وجود عملکرد مناسب روی بعضی کلاس‌ها همچنان دشوار است. نقطه قوت مدل، Recall بالا برای کلاس‌های اقلیت است و نقطه ضعف آن، Precision پایین‌تر همان کلاس‌هاست. بنابراین نتیجه نهایی قابل دفاع است، اما باید همراه با این محدودیت تفسیر شود. نوت‌بوک همچنین مدل نهایی را روی تمام داده آموزشی برازش می‌دهد و در صورت قرار گرفتن فایل group_28_test.csv، خروجی پیش‌بینی را بدون تغییر در منطق پروژه تولید می‌کند.

۶. شرح مشارکت اعضای گروه

رادمهر میرادی: طراحی مسیر علمی پروژه، مطالعه صورت پروژه، تعریف مسئله، شناخت ساختار داده، انجام بخش اصلی EDA، بررسی مقادیر گم‌شده و تکراری، طراحی پیش‌پردازش، استخراج ویژگی‌های زمانی، انتخاب معیارهای ارزیابی، پیاده‌سازی مدل‌ها، انتخاب ویژگی، تحلیل نتایج و نگارش بخش‌های اصلی گزارش.

مریم تقی‌نسب: کمک در اجرای بخشی از کدها، بررسی خروجی‌های اولیه، بازبینی نمودارها و جدول‌ها، کنترل ظاهری گزارش، مشارکت در جمع‌آوری نتایج و بازبینی نسخه نهایی.

هر دو عضو با ساختار کلی داده، مراحل پیش‌پردازش، مدل‌های بررسی‌شده، معیارهای ارزیابی و نتیجه نهایی آشنا هستند.